

地方官员数据库研究平台建设方案

发文	课题组负责人
受文	全体研究成员
日期	2026年7月
性质	内部工作备忘
版本	v3（更新部署、协作方案及成员称谓）

一、背景与目标

本课题组长期维护一个地方官员数据库，围绕该数据库开展政治经济学方向的实证研究。随着成员增加、数据规模扩大，当前以分散文件和口头协调为主的工作方式已难以满足需求，主要面临以下痛点：

- 数据错误难以统一追踪，更正缺乏溯源记录
- 各成员项目进展、研究想法相互隔离，知识难以沉淀
- 关联数据（经济、网络、文本）分散存储，跨数据集查询繁琐
- 代码和方法缺乏共享机制，重复劳动较多

为此，计划建设一个内部研究数据平台，目标是：数据资产统一管理、协作流程标准化、研究知识持续积累。

二、部署方案

平台部署于北大校内服务器，所有数据留存校园网内，不经过任何商业云服务，满足研究数据安全要求。

服务器资源

- 向国发院IT支持或学校高性能计算中心申请一台Linux虚拟机（推荐配置：4核CPU、16GB内存、1TB存储，可按实际数据规模调整）
- 操作系统建议Ubuntu 22.04 LTS，稳定且社区支持完善
- 校内成员通过有线/无线校园网直接访问；校外或居家成员通过北大VPN连接后访问，无需额外配置

数据安全机制

- 所有数据库连接仅在校园网段内开放，不暴露公网端口

- 每日自动备份至另一台校内存储节点或北大网盘（文件级备份）
- 数据库操作全程留有审计日志，任何写入、修改、删除均可追溯

三、平台整体架构

平台分为三层，全部运行于校内服务器：

- 数据层：官员数据库（PostgreSQL）、更正日志表、关联数据集注册、方法与代码库
- 服务层：数据清理协作模块、项目管理模块、跨数据集查询接口、通知系统、权限管理与审计追踪、REST API（供R/Python调用）
- 前端层：数据清理看板、研究进展看板、数据浏览器、管理员视图

推荐技术栈（均为开源可自部署）

- PostgreSQL — 主数据库
- Datasette — 轻量数据浏览器，无需SQL即可查询，适合全体成员日常使用
- Metabase — 数据可视化与报表，图形化查询界面
- FastAPI（Python）— 后端接口层，供R/Python脚本直接调用数据
- Outline — 开源知识库，自部署于校内服务器，替代Notion，用于项目进展与文档管理
- Gitea — 开源Git服务，自部署于校内服务器，替代GitHub，用于代码版本控制

注：Outline和Gitea均为开源工具，可完全部署在校内服务器，无需依赖任何外部商业服务。

四、数据错误报告与更正流程

数据质量维护是平台的核心功能之一。无需数据库专业知识，任何成员均可通过以下方式报告错误：

4.1 错误报告入口

- 平台内置网页表单（部署于校内服务器），填写后直接写入错误队列，无需接触数据库
- 过渡期（平台建设前）：使用共享文档（校内服务器上的固定格式表格）收集错误报告
- 发现错误的常见场景：跑回归时发现异常值、用Datasette浏览时发现不一致、批量描述统计时发现分布异常

4.2 每条更正记录须包含

- 官员ID、字段名、错误值、正确值（必填）
- 信息来源（文献、网页链接等）
- 报告人、发现场景（选填）

4.3 审核与写入流程

- 更正申请提交后，由课题组负责人审核
- 审核通过后由数据库负责人写入主表，同时自动记录时间戳与操作人

- 更正完成后通知全体成员（邮件或平台内消息）
- 历史版本通过valid_from / valid_to字段保留，任何时间点的数据状态均可复现

五、其他核心功能

5.1 项目与研究进展管理

每位成员在Outline知识库中维护研究项目页面，记录项目状态、核心想法、近期进展和待解决问题。项目页面支持关联写作文档（Overleaf项目通过Git URL绑定，或直接粘贴Google Docs链接）及Gitea代码仓库。

5.2 关联数据管理

各类关联数据（经济数据、政商网络数据、文本数据等）独立维护，通过官员ID或"地区-年份"复合键与主库关联。平台提供统一查询接口，支持跨数据集联合查询与导出，R/Python用户可直接通过API调用，无需手动合并文件。

5.3 写作工具集成

项目页面支持绑定Overleaf Git URL，近期先实现链接管理与一键跳转；后续可通过Git接口自动拉取.tex文件，提取标题、摘要和章节结构，同步展示在项目页面上。如有需要，远期可在校内服务器自建Overleaf Community Edition实例，实现数据与写作的完全本地化。

六、分阶段实施计划

阶段	时间	主要工作	交付物
第一阶段 （打基础）	1—2个月	向校内申请服务器资源 部署PostgreSQL，导入现有数据 建立更正日志表结构 部署Datasette数据浏览 建立Outline知识库（项目卡片） 指定数据库维护成员 过渡期错误报告用共享文档收集	可查询数据浏览器 标准化更正流程 成员项目知识库
第二阶段 （上服务）	3—6个月	部署FastAPI接口层 部署Metabase可视化 关联数据集接入 内置错误报告表单上线 部署Gitea代码仓库 Overleaf链接管理	R/Python可调API 数据仪表盘 全校内自托管工具链
第三阶段 （精细化）	6个月	Overleaf元数据自动同步 自建Overleaf实例（可选） 方法库与文档体系完善 数据质量自动巡检脚本	全自动化协作平台 完整本地化工具生态

七、权限分级与使用规范

- 课题组负责人 (PI) : 审核数据更正; 管理成员权限; 发布正式数据版本
- 数据库维护成员 (指定1—2人) : 执行更正写入; 维护服务器; 管理备份
- 项目成员: 提交错误报告; 上传关联数据; 更新项目进展; 只读访问数据库

数据库操作须通过平台接口进行, 任何成员不得直接修改数据库主表, 所有写入操作均须留有记录。

本备忘录仅供课题组内部使用。服务器申请及具体技术配置将在团队会议上进一步商定。